Juan Sebastián Pérez

Ingeniero de IA Senior

Agentes LLM · RAG · Evaluaciones · IA en producción

Bucaramanga, Colombia · Remoto (UTC-5)

juans.perezc@gmail.com
linkedin.com/in/juan-perez-ai-engineer
github.com/Juanllenato
juan-perez-ai.vercel.app

7
productos de IA diseñados y construidos

120+
usuarios activos en un CRM con IA en vivo

1.500+
pruebas automatizadas en los productos

2 días
para lanzar una vertical nueva sobre la base de agentes

PERFIL

Ingeniero de IA senior con más de 5 años en software y más de 3 con sistemas LLM en producción. En AINEATECH lidero la ingeniería de productos de IA: diseñé y construí siete productos para empresas de Colombia y Perú, entre ellos agentes de ventas por WhatsApp, un SaaS de ventas multi-tenant y dos CRM con IA (uno con más de 120 usuarios activos). Me enfoco en lo que hace confiable a un agente: esquemas estrictos, validaciones en código, evaluaciones y costos predecibles.

- Construí una base de agentes reutilizable y la usé en 4 verticales (inmobiliaria, concesionarios, restaurantes y e-commerce). La versión para concesionarios salió en **2 días**.
- Diseñé un CRM con IA con **más de 120 usuarios activos** en Colombia y Perú: asistente RAG sobre datos del negocio, OCR de facturas por WhatsApp y reportes nocturnos.
- **Más de 1.500 pruebas automatizadas** y **más de 75 escenarios de evaluación** con clientes simulados y LLM juez. La línea base del agente inmobiliario dio **0 fugas de datos y 0 cifras sin fuente**.

EXPERIENCIA

Ingeniero de IA Senior, Líder de Productos de IA

2023 – Actualidad

AINEATECH (AINEA Technology LLC) · Houston, TX, EE. UU. · Remoto

- Lidero la entrega de los productos de IA de principio a fin: arquitectura, prompts, elección de modelos, evaluaciones, seguridad, CI/CD y soporte.
- Escribo los loops de agentes sobre la Messages API de Claude con herramientas Zod de esquema estricto, prompts versionados y prompt caching. Un agente solo confirma un pedido si la herramienta funcionó.
- Valido cada respuesta en código antes de enviarla (fugas de datos, precios del catálogo, reglas de política), con un reintento, respuesta segura y traspaso a una persona.
- Enruto entre Claude y modelos abiertos en Together AI (DeepSeek, Kimi, GLM) según costo y benchmarks, con fallbacks y costo medido por turno.
- Aíslo los datos de cada cliente con row-level security en Postgres y cifrado AES-256-GCM; integré WhatsApp Cloud API, Embedded Signup, Conversions API y Marketing API.
- Opero producción con Docker, Caddy y GitHub Actions con rollback automático. Los agentes nuevos arrancan en modo sombra y cada producto tiene ADRs y runbooks.
- Además entregué más de 4 sitios web y e-commerce y automatizaciones n8n con IA (Pontebela, PrevenSalud, Grupo Alianza Vital).

Desarrollador web freelance

2020 – 2023

Independiente · Colombia · Remoto

- Construí sitios web y tiendas en línea para pequeños negocios con WordPress y WooCommerce: temas hijo de Astra a medida, plantillas PHP y CSS mobile-first.
- Llevé cada proyecto de punta a punta: requisitos, diseño, desarrollo, lanzamiento y mantenimiento.

HABILIDADES

IA y LLM

Agentes y tool calling · RAG y búsqueda híbrida · Evals · LLM como juez · Guardrails · Salidas estructuradas · Prompt caching · Defensa contra prompt injection · Voz a texto · OCR / document AI

Modelos

Anthropic Claude · OpenAI · Together AI · DeepSeek · Kimi · GLM · Embeddings Voyage

Backend

TypeScript · Node.js · Fastify · Python · FastAPI · PostgreSQL · Supabase · pgvector · Redis · pg-boss · Celery · Webhooks

Integraciones

WhatsApp Cloud API · Meta CAPI y Ads · Shopify · Stripe · Google Workspace · n8n

Frontend y DevOps

React · Next.js · React Native · Docker · GitHub Actions · Vitest · Playwright

DISPONIBILIDAD

Inmediata
puedo empezar ya

Remoto, UTC-5
mismo horario que EE. UU. (centro)

Contratista o empleado
acepto contratos en USD

EDUCACIÓN

Ingeniería de Sistemas
UTS, Colombia · en curso

Tecnólogo en Desarrollo de Sistemas Informáticos
UTS, Colombia · graduado

IDIOMAS

Español
nativo

Inglés
B1, cómodo por escrito (Slack, PRs, docs)

PORTAFOLIO

Productos de IA destacados

Juan Sebastián Pérez
Ingeniero de IA Senior

En vivo usuarios reales · **Desplegado** corriendo en producción · **Piloto** prueba supervisada con un cliente real

Sin Frontera — PILOTO

Agente de ventas con IA para inmobiliaria B2B, Colombia

Agente de WhatsApp que califica leads y agenda visitas para una firma de inmuebles industriales (unos 100 activos, 1.200–1.500 leads al mes). Búsqueda híbrida con filtros SQL, texto completo en español y embeddings pgvector fusionados con RRF. 11 herramientas, más un asistente de 12 con el que el equipo consulta datos y aprueba cambios. 43 escenarios de evaluación, más de 540 pruebas, 30 ADRs.

TypeScript · Fastify · React · Supabase · pgvector · Claude · Together AI

sinfrontera.aineatech.com

Ainea — DESPLEGADO

SaaS de agente de ventas con IA por WhatsApp

SaaS multi-tenant para pymes de LatAm que cubre el ciclo completo: anuncio en Meta, chat de WhatsApp, agente de ventas, pedido en la tienda y evento de compra en la Conversions API. Alta autoservicio con Embedded Signup, pedidos borrador en Shopify, campañas por Marketing API y Stripe Billing. Cola de turnos en Postgres con bloqueo por conversación, reintentos y cola de errores. Más de 760 pruebas.

TypeScript · PostgreSQL · WhatsApp Cloud API · Meta CAPI · Shopify · Stripe

app.aineatech.com

Ainea CRM — EN VIVO

CRM del equipo comercial

Leads con reparto round-robin por producto, agenda con Google Meet, campañas de correo con seguimiento automático de 3 pasos, métricas y comisiones. La app decide y n8n ejecuta, mediante un outbox transaccional firmado con HMAC. Inicio de sesión con Google, 3 roles y borrado de datos según la Ley 1581.

n8n · Google Meet · Gmail · Google SSO

app.aineatech.com

Ainea Autos — DESPLEGADO

Plataforma de IA para concesionarios de usados, Colombia y Perú

Agente comprador 24/7 por WhatsApp (búsqueda en inventario, simulador de financiación en el servidor, retoma y test drive), CRM web y un asistente de 27 herramientas para dueños y vendedores que propone acciones para que una persona las confirme y envía alertas proactivas. Calificación de leads con reglas; inventario sincronizado desde Google Sheets.

TypeScript · Supabase · Claude · Google Sheets

autos.aineatech.com

Agente de restaurantes BACCA — PILOTO

3 sedes, Bucaramanga, Colombia

Agente de WhatsApp sobre Claude para domicilios, pedidos para recoger y reservas. 13 herramientas estrictas y 4 validaciones deterministas: todo precio debe coincidir con la carta o con un total calculado. Las reservas respetan el aforo con advisory locks de Postgres. Entiende notas de voz y lee la carta desde fotos y PDF. Más de 240 pruebas, 13 escenarios.

Claude · Deepgram · PostgreSQL · WhatsApp Cloud API

PrevenSalud AI CRM — EN VIVO · +120 USUARIOS

CRM con IA multi-tenant, Perú

CRM con IA en producción con más de 120 usuarios activos. Un asistente RAG responde sobre datos reales del negocio sin enviar datos personales al modelo. Las facturas que llegan por WhatsApp pasan por un OCR que prioriza el costo (Tesseract, luego Vision, luego Claude), y cada noche salen reportes PDF redactados por IA.

Python · FastAPI · PostgreSQL RLS · Redis · Celery · Next.js · Docker

crm.prevensalud.pe

Coach de salud con IA agéntica — GITHUB

App móvil, código en GitHub

Coach de IA que opera toda una app React Native por chat y orquesta 13 herramientas: RAG sobre pgvector, registro de comidas con fotos y proyecciones de salud. Backend modular en FastAPI con feature flags por tenant.

React Native · FastAPI · pgvector

github.com/Juanllenato/plataforma-bienestar-ai

Harness de evals y automatizaciones n8n — GITHUB

Código abierto

Harness de evaluación de LLM con datasets versionados, LLM como juez y bloqueo en CI. Flujos n8n de triage de soporte, calificación de leads BANT y aprobación de facturas con detección de fraude y aprobación humana.

LLM como juez · Bloqueo en CI · n8n

github.com/Juanllenato

Casos de estudio, diagramas de arquitectura y un asistente de IA que responde preguntas sobre mi trabajo

juan-perez-ai.vercel.app