

JUAN SEBASTIÁN PÉREZ

Ingeniero de IA Senior · Agentes LLM · RAG · Sistemas de IA en producción

Colombia · Remoto · juans.perez@gmail.com · linkedin.com/in/juan-perez-ai-engineer · github.com/Juanllenato · juan-perez-ai.vercel.app

PERFIL

Ingeniero de IA Senior con más de 5 años construyendo software y más de 3 años llevando sistemas con LLM a producción. Lidero la ingeniería de productos de IA en AINEATECH (Houston, TX), donde diseñé y construí 7 productos de IA para empresas de Colombia y Perú: agentes de ventas con IA por WhatsApp para inmobiliarias, concesionarios y restaurantes, un SaaS multi-tenant de ventas con IA y dos CRM con IA (uno con más de 120 usuarios activos). Construyo agentes confiables, no demos: herramientas con esquemas estrictos, guardas deterministas, evaluaciones con LLM como juez, seguridad multi-tenant y selección de modelos según costo.

LOGROS CLAVE

- Diseñé una **arquitectura de agentes reutilizable en producción** (loop de herramientas, esquemas estrictos, guardas deterministas, traspaso a humanos, multi-tenancy con RLS en Postgres, harness de evaluación) y la reutilicé en **4 verticales**. Sobre ella lancé una vertical nueva (concesionarios) en **2 días**.
- Diseñé un **CRM con IA en producción con más de 120 usuarios activos** en varias empresas de Colombia y Perú (asistente RAG, OCR de facturas por WhatsApp, reportes automáticos).
- Ingeniería guiada por evaluaciones:** más de 1.500 pruebas automatizadas y más de 75 escenarios de evaluación (clientes simulados, evaluadores deterministas, LLM como juez). La línea base del agente inmobiliario dio **0 fugas de datos y 0 cifras sin fuente**.

EXPERIENCIA

Ingeniero de IA Senior — Líder de Productos de IA

2023 – Actualidad

AINEATECH (AINEA Technology LLC) · Houston, TX, EE. UU. · Remoto

- Lidero de punta a punta la entrega de los productos de IA de la empresa: arquitectura, diseño de LLM y prompts, evaluaciones, seguridad, CI/CD y operación en producción.
- Construyo agentes como sistemas, no como prompts: loops de herramientas propios sobre la Messages API de Claude, con herramientas Zod de esquema estricto, salidas estructuradas, prompts versionados y prompt caching. El agente no puede confirmar un pedido o una reserva si la herramienta no se ejecutó con éxito.
- Construí guardas de salida deterministas (canarios de fuga de datos, precios validados contra el catálogo, reglas de política) con una regeneración y respuesta segura, además de escalamiento a humanos por reglas.
- Enrutamiento de LLM según costo entre Anthropic Claude (Opus/Sonnet) y modelos abiertos en Together AI (DeepSeek, Kimi, GLM), con fallbacks, costo medido por turno y selección de modelos con benchmarks.
- Multi-tenancy con row-level security en Postgres, credenciales cifradas con AES-256-GCM y alta de clientes como "configuración, no código". Integración profunda con Meta: WhatsApp Cloud API, Coexistencia, Embedded Signup, Conversions API, Marketing API.
- Operación en producción: Docker + Caddy en Hetzner, CI/CD en GitHub Actions con rollback automático, colas pg-boss, pilotos en modo sombra con revisión humana, ADRs y runbooks por producto.
- Además entregué más de 4 plataformas web y de e-commerce en producción y automatizaciones con IA en n8n para clientes (Pontebela, PrevenSalud, Grupo Alianza Vital).

PRODUCTOS DE IA DESTACADOS

Sin Frontera — Agente de ventas con IA para inmobiliaria B2B (Colombia) **PILOTO**

sinfrontera.aineatech.com

Agente de WhatsApp para una firma de inmuebles industriales (unos 100 activos, 1.200–1.500 leads al mes) que califica leads y agenda visitas. Búsqueda híbrida: filtros SQL, texto completo en español y embeddings pgvector/Voyage, fusionados con RRF. Tiene 11 herramientas, más un asistente interno de 12 herramientas con el que el equipo consulta en lenguaje natural, aprueba cambios y recibe un resumen diario. 43 escenarios de evaluación con prospectos simulados y LLM juez, más de 540 pruebas, 30 ADRs. En piloto supervisado en modo sombra.

TypeScript · Node 24 · Fastify · React · Supabase Postgres · pgvector · pg-boss · Claude · Together AI · Turborepo

Ainea — SaaS de agente de ventas con IA por WhatsApp **DESPLEGADO**

app.aineatech.com

SaaS multi-tenant para pymes de LatAm que cubre el ciclo completo: anuncio en Meta → chat de WhatsApp → agente de ventas con IA → pedido en la tienda → evento de compra en CAPI → recompra. Alta autoservicio con Embedded Signup y Coexistencia de WhatsApp. Pedidos borrador en Shopify, campañas por Marketing API y Stripe Billing (3 planes). El prompt de cada marca se genera desde una plantilla por vertical, un brief y el catálogo. Cola de turnos en Postgres con bloqueo por conversación, reintentos y cola de errores. Más de 760 pruebas.

Ainea CRM — CRM del equipo comercial **EN VIVO**

app.aineatech.com

CRM para el equipo comercial: leads con reparto round-robin por producto, clientes, agenda con Google Meet, campañas de correo con seguimiento automático de 3 pasos, métricas y comisiones. "La app decide, n8n ejecuta" mediante un outbox transaccional firmado con HMAC. Inicio de sesión con Google, 3 roles y flujo de borrado de datos según la Ley 1581.

Ainea Autos — Plataforma de IA para concesionarios de usados (Colombia y Perú) **DESPLEGADO**

autos.aineatech.com

Plataforma multi-tenant: agente comprador 24/7 por WhatsApp (búsqueda en inventario, simulador de financiación calculado en el servidor, registro de retoma, agenda de test drive), CRM web y un asistente de 27 herramientas para dueños y vendedores que propone acciones para que una persona las confirme y envía alertas proactivas. Calificación de leads con motor de reglas determinista; inventario sincronizado desde Google Sheets.

Agente de IA para restaurantes — BACCA, 3 sedes (Bucaramanga, Colombia) **PILOTO**

Agente multi-tenant de WhatsApp sobre Claude para pedidos a domicilio y para recoger, y reservas de mesa. Tiene 13 herramientas estrictas y 4 guardas deterministas (todo precio debe coincidir con la carta o con totales calculados). Las reservas respetan el aforo con advisory locks de Postgres y retención de cupos. Procesa notas de voz (Deepgram) y extrae la carta desde fotos y PDF con Claude Opus. Un restaurante nuevo se da de alta con un comando, como configuración y no como código. Más de 240 pruebas, 13 escenarios de evaluación.

PrevenSalud AI CRM (Perú) **EN VIVO** · +120 USUARIOS

crm.prevensalud.pe

CRM con IA multi-tenant en producción: asistente RAG sobre datos reales del negocio (sin enviar datos personales al modelo), OCR de facturas por WhatsApp con enfoque de costo (Tesseract → Vision → Claude) y reportes PDF redactados por IA cada noche.

Python · FastAPI · PostgreSQL RLS · Redis · Celery · Next.js · Docker

Coach de salud con IA agéntica (app móvil)

github.com/Juanllenato/plataforma-bienestar-ai

Coach de IA que opera toda una app React Native por chat. Orquesta 13 herramientas: RAG sobre pgvector, registro de comidas por visión y proyección de salud. El backend es un monolito modular en FastAPI con feature flags por tenant.

Código abierto: harness de evaluación de LLM · automatizaciones n8n con IA

github.com/Juanllenato

Harness de evaluación de LLM con datasets versionados, LLM como juez y bloqueo en CI. Flujos n8n de triage de soporte, calificación de leads BANT y aprobación de facturas con detección de fraude y aprobación humana.

HABILIDADES TÉCNICAS

IA / LLM: sistemas agénticos y tool calling · RAG y búsqueda híbrida (pgvector, texto completo, RRF) · salidas estructuradas · ingeniería de contexto y prompts · evaluaciones (LLM como juez, usuarios simulados) · guardas y defensa contra prompt injection · voz a texto · OCR / document AI · Anthropic Claude · OpenAI · Together AI (DeepSeek, Kimi, GLM) · embeddings Voyage · conceptos de LangChain/LangGraph

Backend: TypeScript / Node.js (Fastify, Drizzle, Zod) · Python (FastAPI, SQLAlchemy async, Celery) · PostgreSQL / Supabase (RLS, pgvector) · Redis · pg-boss · REST y webhooks (idempotencia, reintentos)

Integraciones: WhatsApp Cloud API y Meta (Embedded Signup, CAPI, Marketing API) · Shopify · Stripe · Google Calendar / Sheets / Gmail · n8n

Frontend y DevOps: React · Next.js · React Native · Tailwind · Docker · Caddy / nginx · VPS Linux (Hetzner) · CI/CD con GitHub Actions · Vitest · Playwright

EDUCACIÓN

Ingeniería de Sistemas — Unidades Tecnológicas de Santander (UTS) · En curso

Tecnólogo en Desarrollo de Sistemas Informáticos — UTS · Graduado

IDIOMAS

Español — Nativo

Inglés — Intermedio (B1), en mejora constante; cómodo en comunicación escrita asíncrona (Slack, PRs, documentación)